

11-Muestreo e Indiferencia estadística

Población y muestra

Población: Conjunto de todos los elementos objeto del estudio que tiene una determinada característica.

Muestra: Es la parte de la población que se observa para extraer información y realizar el estudio.

Muestreo: Proceso mediante el cual se selecciona la muestra de la población.

Para poder determinar la población en un estudio, las características de la misma han de estar definidas perfectamente.

La población puede ser finita o infinita. Una población muy grande puede considerarse infinita.

Para obtener conclusiones válidas es imprescindible que la muestra sea representativa de la población.

Representatividad de la muestra

Para que los resultados obtenidos a partir de una muestra sean fiables, se tienen que cumplir dos condiciones:

- Tener un tamaño adecuado.
- Que sus elementos hayan sido seleccionados de forma aleatoria.

Si se cumplen estas dos condiciones, la muestra es **representativa**. Si la selección no es aleatoria diremos que la muestra es **sesgada**.

Ejemplo Se realiza un sondeo telefónico para determinar el grado de satisfacción de los habitantes con el servicio de limpieza de un ayuntamiento.

Este tipo de muestreo da más oportunidades a las personas que poseen más de un teléfono y elimina a los que no lo poseen. Y por tanto, la muestra no representa al total de la población y los resultados no son fiables. Se ha producido un sesgo de selección.

Tipos de muestreo

Muestreo aleatorio: si los componentes de la muestra son seleccionados al azar y todos los elementos de la población tiene las mismas posibilidades de ser seleccionados.

Muestreo no aleatorio: o no probabilístico, los elementos de la población no tienen la misma probabilidad de ser elegidos.

Muestreo con reposición: cada elemento puede ser seleccionado más de una vez.

Muestreo sin reposición: una vez seleccionado un elemento, no puede volver a ser seleccionado.

Tipos de muestreo aleatorio:

Muestreo aleatorio simple: Todos los elementos tiene la misma probabilidad de ser elegidos para formar parte de la muestra. Es adecuado cuando la población es homogénea respecto a la característica.

Ejemplo. Se quiere averiguar el gasto medio en calefacción de una urbanización. Se eligen al azar a 100 casas.

Muestreo aleatorio sistemático: Se ordenan los elementos de la población. Se selecciona un elemento de la misma al azar, el primer elemento se llama **origen**. Y a continuación se van seleccionando elementos de k en k , siendo k el **coeficiente de elevación**.

$$k = \frac{\text{Nº de elementos de la población}}{\text{Tamaño de la muestra}} = \frac{N}{n}$$

Ejemplo: En un colegio de 600 alumnos de la ESO se quiere elegir un tamaño de muestra de 150 alumnos mediante un muestreo aleatorio sistemático.

$k = \frac{600}{150} = 4$ Se sortea una número del 1 al 4. Supongamos que sale el 2. Los alumnos seleccionados serán el 2, 6, 10, ..., 598

Muestreo aleatorio estratificado: Consiste en dividir la población en subgrupo o estratos homogéneos y en cada uno de ellos tomar muestras aleatorias simples de forma que se mantenga la misma proporción que en la población. Es adecuado cuando la característica que se estudia en la población varía según diferentes grupos como la edad, sexo, nivel económico.

Cuando el tamaño de las muestras en cada estrato es igual, el muestreo es estratificado con **afijación igual**.

$$n_1 = n_2 = \dots = n_k = \frac{n}{k}$$

Cuando el tamaño de cada estrato y el tamaño de su muestra son proporcionales el muestreo es estratificado con **afijación proporcional**.

$$\frac{n_1}{N_1} = \frac{n_2}{N_2} = \dots = \frac{n_k}{N_k} = \frac{n}{N}$$

Siendo N_i el número de elementos de cada estrato y n_i el número de elementos de cada muestra.

Muestreo aleatorio estratificado

Ejemplo: En una población habitan 1200 niños y jóvenes, 6000 adultos y 2000 ancianos. Se desea realizar un estudio para conocer el gasto medio en la factura telefónica. ¿Cuál debe ser la composición de una muestra aleatoria estratificada de tamaño $n = 150$?

Con *afijación igual*: como hay tres estratos tenemos:

$$\frac{150}{3} = 50 \text{ Tomaremos una muestra al azar de cada estrato formada por 50 personas.}$$

Con *afijación proporcional*:

$$\frac{n_1}{N_1} = \frac{n_2}{N_2} = \dots = \frac{n_k}{N_k} = \frac{n}{N} \rightarrow \frac{n_1}{1200} = \frac{n_2}{6000} = \frac{n_3}{2000} = \frac{150}{9200}$$

$$n_1 = 19,56 \approx 20 \quad n_2 = 97,82 \approx 98 \quad n_3 = 32,61 \approx 32$$

Muestreo aleatorio por conglomerado y áreas: Consiste en dividir la población en conjuntos o conglomerados de forma que cada elemento sea heterogéneo y los conglomerados sean muy parecidos entre sí. Se eligen al azar algunos de estos conglomerados y la muestra estará formada por todos los elementos de ellos o por muestras aleatorias simples de estos conglomerados.

Ejemplo: Se desea realizar un estudio sobre el estado de los libros de las bibliotecas municipales de una provincia. ¿Cómo debería seleccionarse la muestra sobre al que se hará el estudio?. Se eligen al azar algunas de las bibliotecas de los municipios de la provincia y se estudia el estado de los libros de las bibliotecas seleccionadas.

Muestreos no aleatorios

En ocasiones no queda más remedio que trabajar con muestras que no son aleatorias.

Muestras erráticas o casuales. Un ejemplo son las encuestas a pie de urna que se producen en las elecciones.

Ventajas: que son de poco coste, que no se precisa de personal muy cualificado

Desventaja: que presentan un alto riesgo de que la muestra no sea representativa. Lo que invalida el resultado.

Muestras intencionadas o racionales: Los elementos son seleccionados por un experto. El departamento de matemáticas de un instituto tiene que elaborar un informe sobre las dificultades de aprendizaje que tienen en esta materia sus alumnos, y el mismo departamento elige la muestra.

Ventaja: puede tener rapidez

Desventaja: existen a los riesgos de que la muestra no sea representativa.

Muestras por cuotas: Son aquellas en que al entrevistador se le dan unos criterios de selección como, por ejemplo, estudiantes universitarios varones y coche propio. Dentro de este colectivo, el entrevistador selecciona su muestra.

Ventajas: proporcionan una información rápida.

Desventaja: pueden producir sesgo en la selección del entrevistador.

Muestras de bola de nieve: Se utilizan con colectivos que, a priori, son difíciles de identificar. Se localiza a un individuo perteneciente al colectivo, este lleva a otro, y así sucesivamente va aumentando la bola de nieve.

Ventajas: recomendada para estudios sociológicos

Desventajas los posibles riesgos de sesgos y que para llevarla a cabo se necesita personal cualificado.

Distribución en el muestreo de una proporción

Si se toman muestras de tamaño $n \geq 30$ de una población de una distribución binomial de parámetros p y q ($1 - p$), la distribución muestral de proporciones se aproxima a una distribución normal, con las siguientes características:

1- *Media:* $\mu = p$

2- *Desviación típica:* $\sigma = \sqrt{\frac{p \cdot q}{n}} = \sqrt{\frac{p \cdot (1-p)}{n}}$

3- A medida que n crece la distribución de $\hat{P}$ se aproxima cada vez más a una distribución normal.

$$\hat{P} \equiv N\left(p, \sqrt{\frac{p \cdot q}{n}}\right)$$

Ejemplo: Se sabe que el 10% de los alumnos del Padilla van regularmente al cine. Se toma una muestra al azar de 100 alumnos, ¿cuál es la probabilidad aproximada de que al menos el 13% de ellos vaya regularmente al cine?.

$$\hat{P} \equiv N\left(0,1, \sqrt{\frac{0,1 \cdot 0,9}{100}}\right) = N(0,1; 0,03)$$

$$P(\hat{P} > 0,13) \Rightarrow z = \frac{x - \mu}{\sigma} = \frac{0,13 - 0,1}{0,03} = 1 \Rightarrow P(z > 1) = 1 - P(z < 1) = 1 - 0,8413 = 0,1587$$

Distribución en el muestreo de medias

Si se toman muestras de tamaño $n \geq 30$ de una población. Por ejemplo se elige una muestra de 100 niños de 15 años y averiguar la talla media en altura que denotamos por μ y calculamos su desviación típica que denotamos por σ . Podemos elegir otras muestras de tamaño 100 y se calculan sus respectivas medias $\bar{x}_1, \bar{x}_2, \bar{x}_3, \dots$ con sus respectivas desviaciones $\bar{\sigma}_1, \bar{\sigma}_2, \bar{\sigma}_3, \dots$. Los distintos valores de $\bar{x}_i$ dan lugar a la variable aleatoria $\bar{X}$ que se denomina **estadístico**. La distribución de los valores de $\bar{X}$ se llama **distribución en el muestreo de la media**. Y tiene las siguientes características:

- 1- La media tiene la misma media que la población μ .
- 2- Desviación típica $\frac{\sigma}{\sqrt{n}}$
- 3- A medida que n crece, la distribución de $\bar{X}$ se aproxima a una normal. $N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$

Ejemplo: Una población de bonsáis tiene una talla media de 17 centímetros y la desviación típica es de 1,8 centímetros. Se toma al azar una muestra de 30 árboles. ¿Cuál es la probabilidad de que la media de las tallas de la muestra sea superior a 15 centímetros?

$$N\left(17, \frac{1,8}{\sqrt{30}}\right) = N(17; 0,33)$$

$$P(\bar{x} > 15) \Rightarrow z = \frac{\bar{x} - \mu}{\sigma} = \frac{15 - 17}{0,33} = -6,06 \Rightarrow P(z > -6,06) = P(z < 6,06) = 1$$

Distribución de las sumas muestrales

Si se toma una muestra aleatoria simple de tamaño n de una variable aleatoria $X: x_1, x_2, x_3, \dots, x_n$ con media μ y desviación típica σ , entonces la variable aleatoria $X := x_1 + x_2 + x_3 + \dots + x_n$ para n suficientemente grande ($n \geq 30$) la distribución muestral de medias X se aproxima a una distribución normal con las siguientes características:

- 1- Media: $n \cdot \mu$
- 2- Desviación típica: $\sigma \cdot \sqrt{n}$
- 3- $X \equiv N(np, \sigma\sqrt{n})$

Ejemplo: Se sabe que el peso medio de unos paquetes que lleva un camión es de 76 kg. Con una desviación típica de 7,4 kg. Por las normativas de seguridad vial, la suma de los paquetes permitida para un tipo determinado de camión no puede superar las 16 toneladas. Si la compañía de transporte quiere transportar 210 bultos, cuál es la probabilidad de que cumpla con la normativa vigente?

La suma de los pesos medios de los paquetes sigue la siguiente distribución.

$X =$ suma de los pesos medios de los paquetes.

$$X \equiv N(np, \sigma\sqrt{n}) = N(210 \cdot 76; 7,4 \cdot \sqrt{210}) = N(15960; 107,24)$$

$$P(X < 16000) \Rightarrow z = \frac{x - \mu}{\sigma} = \frac{16000 - 15960}{107,24} = 0,37 \Rightarrow P(z < 0,37) = 0,6443$$

Distribución muestral de diferencia de medias

Dos poblaciones que sigan distribuciones normales $N(\mu_1, \sigma_1)$ y $N(\mu_2, \sigma_2)$, o bien, si ambas poblaciones tienen distribuciones cualesquiera con media μ_1 y μ_2 , desviaciones típicas σ_1 y σ_2 , y las respectivas muestras son de tamaño n_1 y n_2 , suficientemente grandes, entonces la distribución muestral de diferencia de medidas sigue una distribución normal, con las siguientes características:

- 1- Media: $\mu_1 - \mu_2$
- 2- Desviación típica: $\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$
- 3- $\bar{X}_1 - \bar{X}_2 \equiv N\left(\mu_1 - \mu_2, \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right)$

Ejemplo: El responsable de la sede central de una empresa afirma que las edades de sus empleados siguen una distribución normal de una media de 41 años y una desviación típica de 5 años. Por otro lado, el responsable de una sede de las sucursales de dicha empresa en otro país, ha determinado que sus empleados también tienen edades que se ajustan a una distribución normal con una media de 39 años y desviación típica de 3 años. Con el fin de hacer un estudio comparativo se seleccionan muestras de 40 personas de cada sede de la empresa.

¿Cuál es la probabilidad de que los empleados de la sede central tengan una medida de edad de al menos 3 años mayor que los de la sucursal extranjera?

$$\bar{X}_1 - \bar{X}_2 \equiv N\left(\mu_1 - \mu_2, \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right) = N\left(41 - 39, \sqrt{\frac{5^2}{40} + \frac{3^2}{40}}\right) = N(2; 0,92)$$

$$P(\bar{X}_1 - \bar{X}_2 \geq 3) \Rightarrow z = \frac{3 - 2}{0,92} = 1,09 \Rightarrow P(z \geq 1,09) = 1 - P(z \leq 1,09) = 1 - 0,8621 = 0,1379$$

Teorema central del límite

Sea X una variable aleatoria de una población de media μ y desviación típica σ , no necesariamente normal. La **distribución de las medias de las muestras** ($\bar{X}$) de tamaño n , verifican:

Tienen la misma μ que la población.

Su desviación típica es $\frac{\sigma}{\sqrt{n}}$ y, por tanto, disminuye al aumentar n .

A partir de $n \geq 30$ es prácticamente normal. $N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$

Las distribuciones de las medias muestrales será una normal si la distribución de partida es normal, independientemente del tamaño de la muestra.

Si la distribución de partida no es normal, el tamaño de la muestra debe ser superior o igual a 30.

Estimación puntual

Se desea saber cuál es la proporción de habitantes de una ciudad con edades comprendida entre 16 y 60 años que tienen móvil. Para ello se encarga a una empresa de encuestas que realice el citado estudio.

La empresa escoge aleatoriamente una muestra de 2000 personas y se estudia la proporción que tiene móvil, a esta proporción es lo que se llama **estimador o estimador puntual**. El resultado obtenido es que tiene móvil 1650 personas, es decir un valor de 0,825 o el 82,5 % y este valor se llama **estimación puntual**.

Parámetro: Es un valor numérico que describe una característica de una población.

Estadístico: Es un valor numérico que describe una característica de la muestra.

Estimador puntual: Es un estadístico que se usa para estimar un parámetro poblacional. Por tanto, es una variable aleatoria en el muestreo que tiene su correspondiente distribución muestral.

Estimación puntual. Es el valor numérico que toma el estimador puntual para una muestra determinada.

Media muestral: Dada una muestra $\{x_1, x_2, x_3, \dots, x_n\}$ de una población que sigue una distribución normal de media μ desconocida, un estimador puntual para la media poblacional μ es la media muestral.

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

Ejemplo: La media semanal de horas de estudio de cuatro amigos es de 2, 3, 5, 4 respectivamente. ¿Cuál puede considerarse la media de horas semanales de estudio de los cuatro amigos.

$$\bar{x} = \frac{2 + 3 + 5 + 4}{4} = 3,5$$


Proporción muestral: Dada una muestra $\{x_1, x_2, x_3, \dots, x_n\}$ de una población que sigue una distribución binomial cuyo parámetro p es desconocido, un estimador puntual para el parámetro p es la proporción muestral:

$$\hat{p} = \frac{\sum_{i=1}^n x_i}{n}$$


Ejemplo: En un colegio se toma una muestra de 150 alumnos, de los cuales 50 practican deporte. Determina y calcula un estimador puntual para la proporción de personas que practican deporte en la ciudad.

$$\hat{p} = \frac{50}{150} = 0,33 \Rightarrow 33,3 \%$$


Sesgo y eficiencia




Estimador inexacto y no eficiente



Estimador exacto y no eficiente



Estimador exacto y eficiente



Estimador inexacto y eficiente

Un estimador es **centrado o inexacto** si su media coincide con el valor del parámetro que se va a estimar.

La diferencia entre el verdadero valor del parámetro que se estima y la media del estimador mide el error cometido al utilizar el estimador, y se denomina **sesgo**.

Un estimador es **eficiente** cuando su varianza es mínima.

Estimación por intervalos de confianza

Intervalo de confianza: Es el intervalo que contiene al parámetro que se está estimando con un cierto nivel de confianza.

Estimador por intervalo: es un par de estadísticos que se usan para estimar un parámetro poblacional. Por tanto, son un par de variables aleatorias en el muestreo que tienen su correspondiente distribución muestral.

Estimación por intervalo. Son los valores numéricos que toma el estimador por intervalo para una muestra determinada, es decir, son los extremos del intervalo de confianza.

Nivel de confianza $(1 - \alpha)$: Significa que el $(1 - \alpha) \cdot 100\%$ de los intervalos de confianza contienen el parámetro poblacional que se está estimando.

A cada nivel de confianza (N_c) le corresponde un **valor crítico** ($z_{\alpha/2}$) correspondiente a la distribución normal $N(0, 1)$ y que cumple:

$$P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha \quad \text{a los extremos les llama límites de confianza.}$$

Determinación del valor crítico $z_{\alpha/2}$: Corresponde a un nivel de confianza N_c en tanto por ciento, se calcula mediante la expresión:

$$P(Z \leq z_{\alpha/2}) = \frac{1 + \frac{N_c}{100}}{2} \quad \text{y después buscamos el resultado dentro de las tablas de distribución normal.}$$

Ejemplo: Si fijamos el nivel de confianza $N_c = 95\%$ hallar el valor crítico $z_{\alpha/2}$


$$P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 0,95$$

$$P(Z \leq z_{\alpha/2}) = \frac{1 + \frac{95}{100}}{2} = 0,975, \text{ buscando en las tablas de distribución normal, el número 0,975 corresponde a 1,96}$$

Margen de error: Es la diferencia entre los extremos superior e inferior del intervalo de confianza.

Intervalos característicos en distribuciones normales cualesquiera. En una distribución $N(\mu, \sigma)$ el intervalo correspondiente a una probabilidad $p = 1 - \alpha$ es:

$$(\mu - z_{\alpha/2} \cdot \sigma, \mu + z_{\alpha/2} \cdot \sigma)$$



Ejemplo: Hallar el intervalo característico correspondiente para 50 %; 90 %; 95 %; 99 %

$$50\% \Rightarrow 1 - \alpha = 0,5 \Rightarrow P(Z \leq z_{\alpha/2}) = \frac{1 + \frac{50}{100}}{2} = 0,75 \xrightarrow{\text{buscando en las tablas}} z_{\alpha/2} = 0,68 \Rightarrow (\mu - 0,68 \cdot \sigma, \mu + 0,68 \cdot \sigma)$$

$$90\% \Rightarrow 1 - \alpha = 0,9 \Rightarrow P(Z \leq z_{\alpha/2}) = \frac{1 + \frac{90}{100}}{2} = 0,95 \xrightarrow{\text{buscando en las tablas}} z_{\alpha/2} = 1,645 \Rightarrow (\mu - 1,645 \cdot \sigma, \mu + 1,645 \cdot \sigma)$$

$$95\% \Rightarrow 1 - \alpha = 0,95 \Rightarrow P(Z \leq z_{\alpha/2}) = \frac{1 + \frac{95}{100}}{2} = 0,975 \xrightarrow{\text{buscando en las tablas}} z_{\alpha/2} = 1,96 \Rightarrow (\mu - 1,96 \cdot \sigma, \mu + 1,96 \cdot \sigma)$$

$$99\% \Rightarrow 1 - \alpha = 0,99 \Rightarrow P(Z \leq z_{\alpha/2}) = \frac{1 + \frac{99}{100}}{2} = 0,995 \xrightarrow{\text{buscando en las tablas}} z_{\alpha/2} = 2,575 \Rightarrow (\mu - 2,575 \cdot \sigma, \mu + 2,575 \cdot \sigma)$$

Ejemplo: En una distribución normal $N(40, 5)$, obtener los intervalos característicos para 50 % y 99 %

$$50\% \Rightarrow 1 - \alpha = 0,5 \Rightarrow z_{\alpha/2} = 0,68 \Rightarrow (40 - 0,68 \cdot 5, 40 + 0,68 \cdot 5) = (36,6; 43,4)$$

$$99\% \Rightarrow 1 - \alpha = 0,99 \Rightarrow z_{\alpha/2} = 2,575 \Rightarrow (40 - 2,575 \cdot 5, 40 + 2,575 \cdot 5) = (27,125; 52,875)$$

Ejemplo: Se sabe que $(35,12; 38,54)$ es un intervalo de confianza, al 95%, para la media de una variable aleatoria. ¿Cuál es el error cometido?. ¿Cuál es la media?.

Nivel de confianza $1 - \alpha = 0,95$

Nivel de significación $\alpha = 1 - 0,95 = 0,05$, por tanto, el valor crítico será $z_{\alpha/2} = \frac{z_{0,05}}{2} = z_{0,025}$

El error máximo corresponderá al radio del intervalo. $E = \frac{38,54 - 35,12}{2} = 1,71$

La media estará en el punto medio del intervalo. $\bar{x} = \frac{38,54 + 35,12}{2} = 36,83$

Intervalo de confianza para la media poblacional

Un intervalo de confianza para la media poblacional de una distribución normal con desviación típica σ conocida y un nivel de confianza $1-\alpha$ construido a partir de una muestra de tamaño n , es:


$$\left(\bar{x} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right)$$

Si σ es desconocida y n es grande ($n \geq 30$), el intervalo de confianza viene dado por:

$$\left(\bar{x} - z_{\alpha/2} \cdot \frac{\hat{\sigma}}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \cdot \frac{\hat{\sigma}}{\sqrt{n}} \right) \text{ donde } \hat{\sigma}^2 \text{ es la cuasivarianza muestral } \hat{\sigma}^2 = \sigma^2 \cdot \frac{n}{n-1}$$

Error máximo admisible en la estimación de la media poblacional utilizando el intervalo de confianza para la media con un nivel de confianza $1-\alpha$ es:

$E = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$ el error es igual o menor que la mitad de la amplitud del intervalo, es decir, el radio del intervalo



Margen del error admisible: es la amplitud del intervalo, $2E$

Tamaño de la muestra: despejando n de la fórmula anterior, podemos calcular el tamaño mínimo para que se cumplan las condiciones.

$$E = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \Rightarrow \sqrt{n} = z_{\alpha/2} \frac{\sigma}{E} \Rightarrow n = \left(z_{\alpha/2} \frac{\sigma}{E} \right)^2$$

Ejemplo: Se ha tomado una muestra aleatoria de 100 individuos a los que se les ha preguntado la cantidad de dinero que tienen en la cartera, obteniéndose una media muestral de 110 €. Se sabe que la desviación típica de la población es de 20 €.

- Obtener un intervalo de confianza, al 90%, para la cantidad de dinero en la cartera de la población.
- ¿Cuál es el error máximo cometido con la estimación anterior?.
- Si deseamos que el error cometido, con el mismo nivel de confianza, sea de la décima parte del apartado anterior, ¿cuál ha de ser el tamaño de la muestra?.

a) Intervalo de confianza del 90%

$$90\% \Rightarrow 1-\alpha = 0,9 \Rightarrow P(Z \leq z_{\alpha/2}) = \frac{1 + \frac{90}{100}}{2} = 0,95 \xrightarrow{\text{buscando en las tablas}} z_{\alpha/2} = 1,645$$

$$\left(\bar{x} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right) = \left(100 - 1,645 \cdot \frac{20}{\sqrt{100}}, 100 + 1,645 \cdot \frac{20}{\sqrt{100}} \right) = (106,71; 113,29)$$

b) El error máximo cometido:

$$E = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} = 1,645 \cdot \frac{20}{\sqrt{100}} = 3,29$$

c) El tamaño de la muestra con la décima parte del error anterior

$$0,10 \cdot 3,29 = 0,329$$

$$n = \left(z_{\alpha/2} \frac{\sigma}{E} \right)^2 = 1,645 \cdot \frac{20}{0,329} = 100^2 = 10.000$$

Intervalo de confianza para el parámetro p de un binomial

Un intervalo de confianza para el parámetro p de una $B(n, p)$ es:

$$\left(\hat{p} - z_{\alpha/2} \cdot \sqrt{\frac{\hat{p} \cdot (1 - \hat{p})}{n}}, \quad \hat{p} + z_{\alpha/2} \cdot \sqrt{\frac{\hat{p} \cdot (1 - \hat{p})}{n}} \right)$$

Donde $\hat{p}$ es la proporción de la muestra.

$z_{\alpha/2}$ es el nivel crítico para el nivel de confianza α

n es muy grande lo que equivale a $np > 5$ y $n(1 - p) > 5$

Error máximo admisible en la estimación de la proporción utilizando el intervalo de confianza para la proporción con un nivel de confianza $1 - \alpha$ es su radio:

$$E = z_{\alpha/2} \cdot \sqrt{\frac{\hat{p} \cdot (1 - \hat{p})}{n}}$$

Cuanto mayor sea n , menor será el error cometido.

Cuanto mayor sea $1 - \alpha$, mayor será $z_{\alpha/2}$ y, por tanto, también el error.

Tamaño de la muestra: despejando n de la fórmula anterior, podemos calcular el tamaño mínimo para que se cumplan las condiciones.

$$E = z_{\alpha/2} \cdot \sqrt{\frac{\hat{p} \cdot (1 - \hat{p})}{n}} \Rightarrow \sqrt{n} = z_{\alpha/2} \cdot \frac{\sqrt{\hat{p} \cdot (1 - \hat{p})}}{E} \Rightarrow n = z_{\alpha/2}^2 \frac{\hat{p} \cdot (1 - \hat{p})}{E^2}$$

Ejemplo: En un control de calidad se analizó una muestra aleatoria de 750 tornillos resultando defectuosos 80 de ellos. Hallar:

- Un intervalo de confianza para la proporción de tornillos defectuosos en el conjunto de producción con 99% de confianza..
- ¿Cuál es el error máximo cometido con la estimación anterior?.
- Si deseamos que el error cometido, con el mismo nivel de confianza, sea de la décima parte del apartado anterior, ¿cuál ha de ser el tamaño de la muestra?.

a) Intervalo de confianza del 99%

$$99\% \Rightarrow 1 - \alpha = 0,99 \Rightarrow P(Z \leq z_{\alpha/2}) = \frac{1 + \frac{99}{100}}{2} = 0,995 \xrightarrow{\text{buscando en las tablas}} z_{\alpha/2} = 2,575$$

$$\hat{p} = \frac{80}{750} = 0,11 \Rightarrow \hat{q} = 1 - \hat{p} = 1 - 0,11 = 0,89$$

$$\left(\hat{p} - z_{\alpha/2} \cdot \sqrt{\frac{\hat{p} \cdot (1 - \hat{p})}{n}}, \quad \hat{p} + z_{\alpha/2} \cdot \sqrt{\frac{\hat{p} \cdot (1 - \hat{p})}{n}} \right) = \left(0,11 - 2,575 \cdot \sqrt{\frac{0,11 \cdot 0,89}{750}}, \quad 0,11 + 2,575 \cdot \sqrt{\frac{0,11 \cdot 0,89}{750}} \right) = (0,0880; 0,139)$$

b) El error máximo cometido:

$$E = z_{\alpha/2} \cdot \sqrt{\frac{\hat{p} \cdot (1 - \hat{p})}{n}} = 2,575 \cdot \sqrt{\frac{0,11 \cdot 0,89}{750}} = 0,029$$

c) El tamaño de la muestra con la décima parte del error anterior

$$0,10 \cdot 0,029 = 0,0029$$

$$n = z_{\alpha/2}^2 \frac{\hat{p} \cdot (1 - \hat{p})}{E^2} = 2,575^2 \frac{0,11 \cdot 0,89}{0,0029^2} = 77.186,46 \approx 77.187$$



Intervalo de confianza para la diferencia de medias

Un intervalo de confianza para la diferencia de medias poblacionales de dos distribuciones normales $N(\mu_1, \sigma_1)$ y $N(\mu_2, \sigma_2)$, con desviaciones típicas σ_1 y σ_2 conocidas, con un nivel de confianza $1-\alpha$ construido a partir de dos muestras de tamaño n_1 y n_2 , es:

$$\left((\bar{x}_1 - \bar{x}_2) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{x}_1 - \bar{x}_2) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right)$$

Si σ_1 y σ_2 son desconocidas y n_1 y n_2 son grandes ($n_1 \geq 30$ y $n_2 \geq 30$) el intervalo de confianza viene dado por:

$$\left((\bar{x}_1 - \bar{x}_2) - z_{\alpha/2} \sqrt{\frac{\hat{\sigma}_1^2}{n_1} + \frac{\hat{\sigma}_2^2}{n_2}}, (\bar{x}_1 - \bar{x}_2) + z_{\alpha/2} \sqrt{\frac{\hat{\sigma}_1^2}{n_1} + \frac{\hat{\sigma}_2^2}{n_2}} \right)$$

Donde $\hat{\sigma}_1^2$ y $\hat{\sigma}_2^2$ son las cuasivarianzas de cada muestra

Error máximo admisible en la estimación de la diferencia de medias utilizando el intervalo de confianza para la diferencia de medias con un nivel de confianza $1-\alpha$ es su radio:

$$E = z_{\alpha/2} \cdot \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

Cuanto mayor sean los tamaños de las muestras, menor será el error cometido.

Cuanto mayor sea $1-\alpha$, mayor será $z_{\alpha/2}$ y, por tanto, también el error.

Ejemplo: En un hospital se realiza un estudio sobre la influencia del estrés en el peso de los bebés al nacer. Se consideran dos grupos de mujeres embarazadas: aquellas que viven en el campo y aquellas que viven en la ciudad, y se obtienen los siguientes datos sobre el peso de sus hijos.

	Muestra	Peso medio de los bebés	Desviación típica
Campo	$n_1 = 320$	$\bar{x}_1 = 3,8$	$\sigma_1 = 0,6$
Ciudad	$n_2 = 240$	$\bar{x}_2 = 3,4$	$\sigma_2 = 0,8$

Decide cómo influye que la madre viva en el campo o en la ciudad en el peso de su hijo al nacer, utilizando un intervalo de confianza para la diferencia de medias con un nivel de confianza del 95%.

Intervalo de confianza del 95%

$$95\% \Rightarrow 1-\alpha = 0,95 \Rightarrow P(Z \leq z_{\alpha/2}) = \frac{1 + \frac{95}{100}}{2} = 0,975 \xrightarrow{\text{buscando en las tablas}} z_{\alpha/2} = 1,96$$

$$\begin{aligned} & \left((\bar{x}_1 - \bar{x}_2) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{x}_1 - \bar{x}_2) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right) = \\ & = \left((3,8 - 3,4) - 1,96 \sqrt{\frac{0,6^2}{320} + \frac{0,8^2}{240}}, (3,8 - 3,4) + 1,96 \sqrt{\frac{0,6^2}{320} + \frac{0,8^2}{240}} \right) = (0,279; 0,520) \end{aligned}$$

Hay una diferencia positiva entre los pesos de los bebés $0,279 < \mu_1 - \mu_2 < 0,520$ luego el peso medio de un bebé de una madre que viva en el campo supera como mínimo en 0,279 kg y como máximo en 0,520 kg al de un bebé de una madre que viva en la ciudad, con una probabilidad de 0,95.

RESUMEN FÓRMULAS



Distribuciones en el muestreo

Las muestras deben ser de tamaño $n \geq 30$

De la media	De la suma	De una proporción	De la diferencia de medias
$N\left(\mu; \frac{\sigma}{\sqrt{n}}\right)$	$N(n\mu, \sigma\sqrt{n})$	$N\left(p, \sqrt{\frac{p \cdot q}{n}}\right)$	$N\left(\mu_1 - \mu_2; \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right)$

Intervalo de confianza

(estimador - $z_{\alpha/2} \cdot$ desviación típica , estimador + $z_{\alpha/2} \cdot$ desviación típica)

Parámetro	Intervalo de confianza	Error máximo admisible	Tamaño de la muestra
Media μ	$\left(\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right)$	$E = z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$	$n = \left(z_{\alpha/2} \frac{\sigma}{E}\right)^2$
Proporción p	$\left(\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p} \cdot (1-\hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p} \cdot (1-\hat{p})}{n}}\right)$	$E = z_{\alpha/2} \sqrt{\frac{\hat{p} \cdot (1-\hat{p})}{n}}$	$n = z_{\alpha/2}^2 \frac{\hat{p} \cdot (1-\hat{p})}{E^2}$
Diferencia de medias $\mu_1 - \mu_2$	$\left((\bar{x}_1 - \bar{x}_2) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{x}_1 - \bar{x}_2) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right)$	$E = z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$	